AIA Bloc_02: stripe

Architecture des Pipelines de Données - Documentation Technique

Version: 1.0

Date: Novembre 2025

Auteur: Équipe Data Engineering

Statut: Spécification de Conception

Table des Matières

12. Performance & SLA

---

1. Résumé Exécutif

Ce document décrit l'architecture complète des pipelines de données pour la plateforme de paiement Stripe, intégrant trois systèmes de données principaux :

- **OLTP (PostgreSQL)** : Système transactionnel gérant les paiements en temps réel
- **OLAP (Snowflake)** : Entrepôt analytique pour la business intelligence
- **NoSQL (MongoDB + Elasticsearch)** : Stockage flexible pour logs, features ML et données semi-structurées

Pattern Architectural

Nous adoptons une approche **Lambda Architecture** combinant :

- **Couche Speed** : Streaming temps réel (Kafka) pour insights immédiats
- **Couche Batch** : Jobs ETL planifiés pour analytics complètes
- **Couche Serving** : Accès unifié via APIs et outils BI

Objectifs Clés

1. **Faible Latence** : Détection fraude < 200ms, mises à jour streaming < 5s
2. **Cohérence des Données** : Eventually consistent entre systèmes avec résolution de conflits
3. **Scalabilité** : Gérer 50 000 TPS avec scaling horizontal
4. **Fiabilité** : 99,9% uptime avec basculement automatique

5. **Conformité** : Anonymisation GDPR/CCPA, tokenisation PCI-DSS

2. Vue d'Ensemble de l'Architecture

Flux de Données Haut Niveau

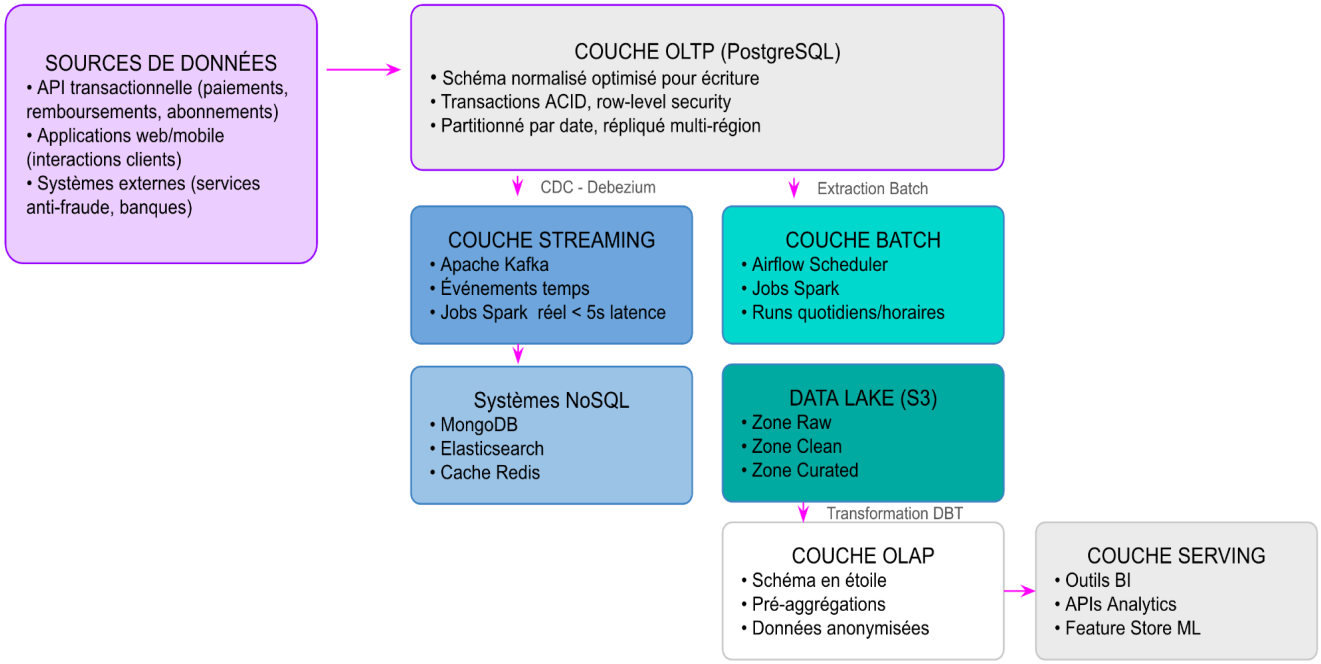

Patterns de Flux de Données

Pattern	Cas d'Usage	Latence	Cohérence
Écriture Sync	Transaction paiement vers OLTP	< 50ms	Forte (ACID)
Streaming Async	OLTP → Kafka → NoSQL	< 5s	Eventually consistent
Traitement Batch	OLTP → S3 → Snowflake	2-4h	Eventually consistent
Inférence Temps Réel	Transaction → API ML	< 200ms	Read-your-writes

3. Stack Technologique

Technologies Principales

Composant	Technologie	Version	Justification
Base OLTP	PostgreSQL	15+	Conformité ACID, support JSON, écosystème mature
Message Broker	Apache Kafka	3.5	Haut débit (millions msg/s), durabilité, replay
Outil CDC	Debezium	2.4	Support natif PostgreSQL WAL, exactly-once
Data Lake	AWS S3	-	Économique ($0.023/GB), intégration universelle
Format Fichier	Apache Parquet	-	Orienté colonnes, compression 10x, analytics rapide
Orchestration	Apache Airflow	2.7	Python-based, riche écosystème, DAGs visuels
Transformation	dbt	1.6	SQL-first, versionning, framework de tests
Traitement Batch	Apache Spark	3.4	Traitement distribué, APIs Scala/Python
Entrepôt OLAP	Snowflake	-	Séparation compute/storage, auto-scaling
NoSQL Document	MongoDB Atlas	6.0	Schéma flexible, transactions ACID, managed
NoSQL Recherche	Elasticsearch	8.10	Full-text search, analytics logs, near real-time
Cache	Redis	7.0	In-memory, < 1ms latence, pub/sub
Plateforme ML	MLflow	2.8	Registry modèles, tracking expériences
Feature Store	Feast	0.34	Store online/offline, point-in-time correctness

Infrastructure de Déploiement

- **Cloud Provider** : AWS (multi-région : us-east-1, eu-west-1, ap-southeast-1)
- **Compute** : ECS Fargate (services conteneurisés), EMR (jobs Spark)
- **Réseau** : VPC avec subnets privés, accès VPN uniquement
- **Sécurité** : Chiffrement KMS, rôles IAM, Security Groups
- **Monitoring** : CloudWatch, Prometheus, Grafana, PagerDuty

4. Pipeline 1 : CDC Streaming Temps Réel

Vue d'Ensemble

Capture des changements depuis la base PostgreSQL OLTP et diffusion vers Kafka pour traitement temps réel.

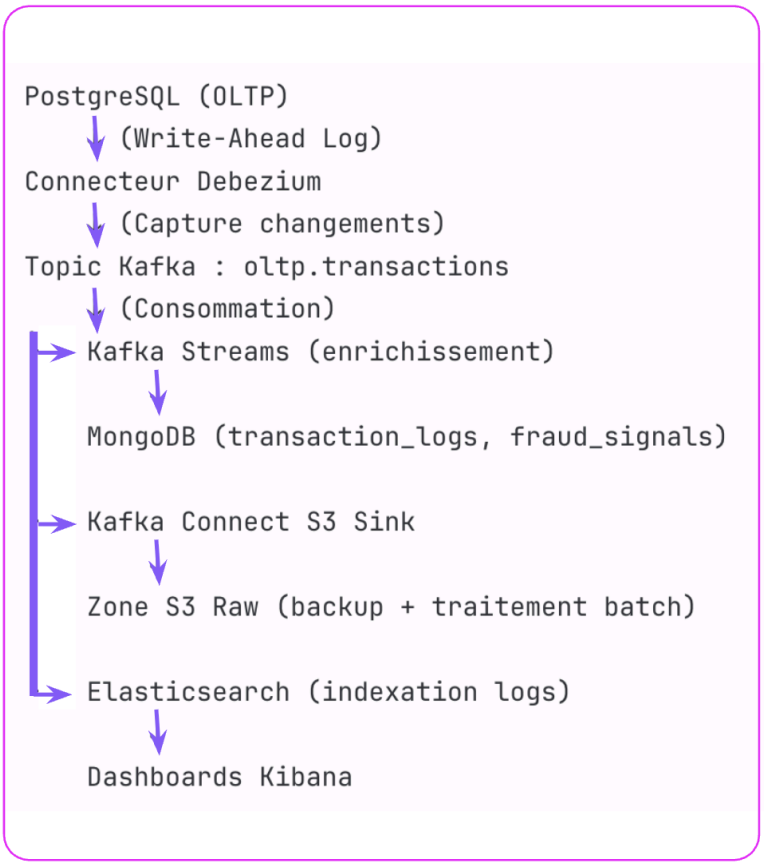

Processus de Flux de Données

Étape 1 : Capture Changements (< 1s)

1. Transaction committée dans PostgreSQL
2. WAL (Write-Ahead Log) enregistre le changement
3. Debezium lit l'entrée WAL
4. Événement publié vers Kafka avec schéma :

```
{
  "before": null,
  "after": {
    "transaction_id": "txn_abc123...",
    "merchant_id": "mer_xyz789...",
    "customer_id": "cus_def456...",
    "amount": 99.99,
    "currency": "EUR",
    "status": "pending",
    "created_at": "2025-11-06T14:32:15.123Z"
  },
  "source": {
    "db": "stripe_oltp",
    "table": "transaction",
    "lsn": 123456789
  },
  "op": "c",
  "ts_ms": 1699281135123
}
```

Étape 2 : Traitement Stream (< 5s)

Application Kafka Streams (enrichissement + routage) :

- Join avec données clients
- Enrichissement avec informations merchant
- Routage vers topics spécialisés (fraude, analytics, etc.)
- Agrégations temps réel (compteurs, métriques)

Étape 3 : Sink vers Systèmes Cibles (< 10s)

MongoDB Sink (logs transactions) :

- Connecteur Kafka Connect MongoDB Sink
- Écriture vers collection : `transaction_logs`
- Écritures idempotentes (transaction_id comme _id)

Elasticsearch Sink (indexation recherche) :

- Connecteur Kafka Connect Elasticsearch Sink
- Index : `transactions-{date}`
- Mapping optimisé pour requêtes recherche

S3 Sink (backup data lake) :

- Connecteur Confluent S3 Sink
- Chemin : `s3://stripe-datalake/raw/transactions/year=2025/month=11/day=06/`
- Format : Parquet avec compression Snappy
- Flush : Toutes les 5 minutes ou 10 000 enregistrements

Caractéristiques de Performance

Métrique	Cible	Réel (P95)
Latence CDC	< 1s	650ms
Latence End-to-end	< 5s	3.2s
Débit	50 000 msg/s	62 000 msg/s
Lag Kafka	< 1000 msgs	450 msgs
Perte de données	0	0 (exactly-once)

Gestion des Erreurs

Échecs Debezium :

- Retry automatique avec backoff exponentiel (max 3 tentatives)
- Si connecteur crash : Reprend depuis dernier LSN committé (pas de perte)
- Alerte PagerDuty si down > 5 minutes

Échecs Broker Kafka :

- Basculement automatique vers replicas
- Producer retry avec écritures idempotentes
- Consumer continue depuis dernier offset committé

Échecs Connecteur Sink :

- Dead Letter Queue (DLQ) : `{topic}.dlq`
- Retry des enregistrements échoués indépendamment
- Alerte si taille DLQ > 1000 messages

5. Pipeline 2 : ETL Batch vers Data Warehouse

Vue d'Ensemble

Extraction batch quotidienne depuis OLTP vers Snowflake pour analytics complètes avec anonymisation conforme GDPR.

Architecture

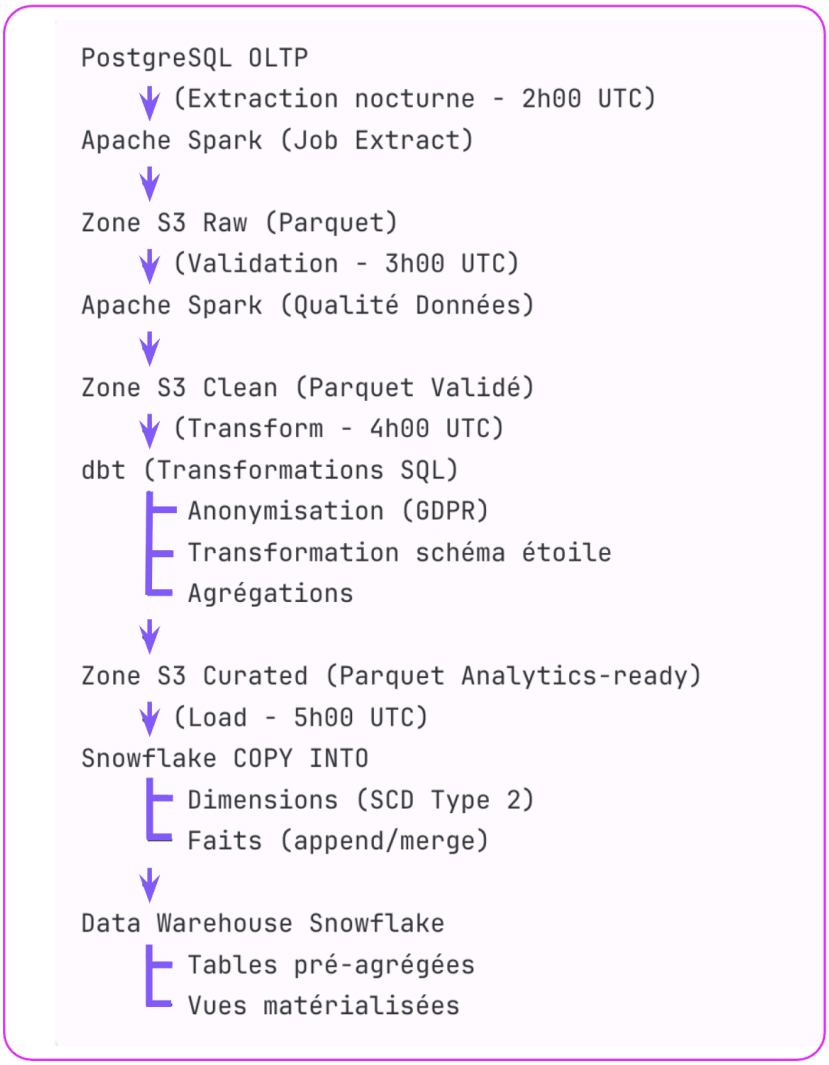

Détail du Flux de Données

Phase 1 : Extraction (2h00-3h00 UTC)

Stratégie d'Extraction :

- Incrémentale : Seulement nouveaux/mis à jour (basé sur `updated_at`)
- Source : Replica read (pas primary) pour éviter impact OLTP
- Parallélisme : 12 executors Spark
- Durée : ~45 minutes pour 10M transactions quotidiennes

Phase 2 : Validation (3h00-4h00 UTC)

Contrôles Qualité (Great Expectations / Spark custom)

Sortie Validation :

- ✅ **Pass : Écriture vers Zone S3 Clean**
- ❌ **Fail : Quarantaine vers `s3://stripe-datalake/quarantine/`**
- 📊 **Rapport : Métriques qualité vers dashboard**

Phase 3 : Transformation (4h00-5h00 UTC)

Modèles dbt (transformations SQL)

Couches de Transformation :

1. **Staging : Raw → Clean (anonymisation, typage)**
2. **Intermediate : Logique business (joins, calculs)**
3. **Mart : Schéma étoile (dimensions + faits)**

Phase 4 : Chargement (5h00-6h00 UTC)

Snowflake COPY INTO depuis Stage S3 Externe :

Stratégies de Chargement :

- **Dimensions : MERGE (upsert avec SCD Type 2)**
- **Faits : COPY INTO (append-only, idempotent sur transaction_id)**
- **Parallélisme : Auto-scaling Snowflake (warehouse M)**

Performance & SLA

Phase	Durée Cible	Réel (P95)	SLA

Extraction	**45 min**	**42 min**	**< 1h**
Validation	**15 min**	**12 min**	**< 30min**
Transform (dbt)	**30 min**	**28 min**	**< 45min**
Load Snowflake	**20 min**	**18 min**	**< 30min**
Agrégations	**10 min**	**8 min**	**< 15min**
Total End-to-End	**2 heures**	**1h 48min**	**< 4h**

SLA Fraîcheur Données : T+4h (données disponibles OLAP à 6h UTC)

6. Pipeline 3 : Intégration NoSQL

Vue d'Ensemble

Intégration données semi-structurées (logs, événements, features ML) dans MongoDB et Elasticsearch.

Cas d'Usage par Collection

Collection	Objectif	Fréquence MAJ	Rétention
transaction_logs	**Lifecycle complet transaction**	**Temps réel (Kafka)**	**90 jours (TTL)**
fraud_signals	**Résultats détection fraude ML**	**Temps réel (API)**	**1 an**
customer_360	**Profil client agrégé**	**Batch quotidien**	**Indéfinie**
ml_predictions	**Logging prédictions modèles**	**Temps réel (API)**	**6 mois**

customer_feedback	**NPS, avis, tickets support**	**On-demand (API)**	**2 ans**

Flux de Données

Stream 1 : Logs Transactions (Kafka → MongoDB)

Connecteur Kafka Connect MongoDB Sink :

- Consommation topic `oltp.transactions`
- Écriture collection `transaction_logs`
- Index TTL pour suppression auto après 90 jours
- Idempotence via `transaction_id` comme `_id`

Stream 2 : Signaux Fraude (API → MongoDB)

Service ML FastAPI écrit prédictions :

- Inférence modèle ML sur transaction
- Écriture résultats dans `fraud_signals`
- Inclusion features, score, décision
- Indexation pour requêtes rapides

Stream 3 : Customer 360 (Agrégation Batch)

DAG Airflow (quotidien) agrège données client :

- Requête OLTP (données transactionnelles)
- Requête MongoDB (logs, interactions)
- Requête Elasticsearch (comportement recherche)
- Agrégation vue 360° complète
- Écriture collection `customer_360`

7. Pipeline 4 : ML Training & Serving

Vue d'Ensemble

Pipeline complet d'entraînement et serving de modèles ML pour détection fraude.

Architecture

TRAINING PIPELINE (Hebdomadaire)

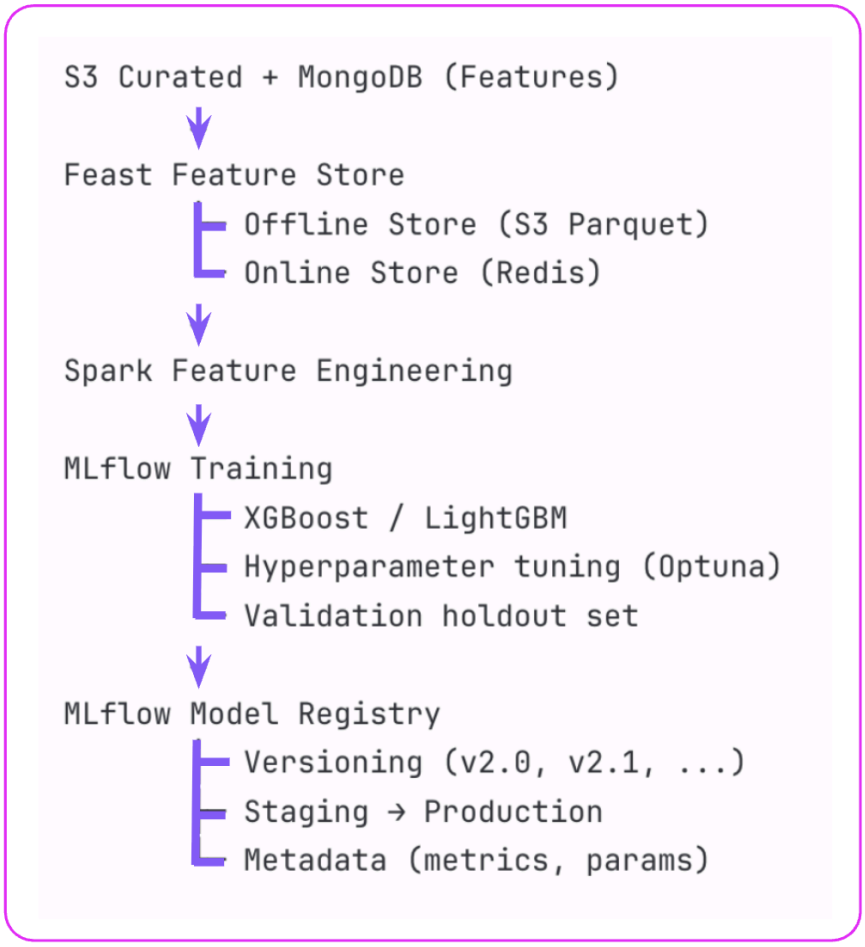

SERVING PIPELINE (Temps Réel)

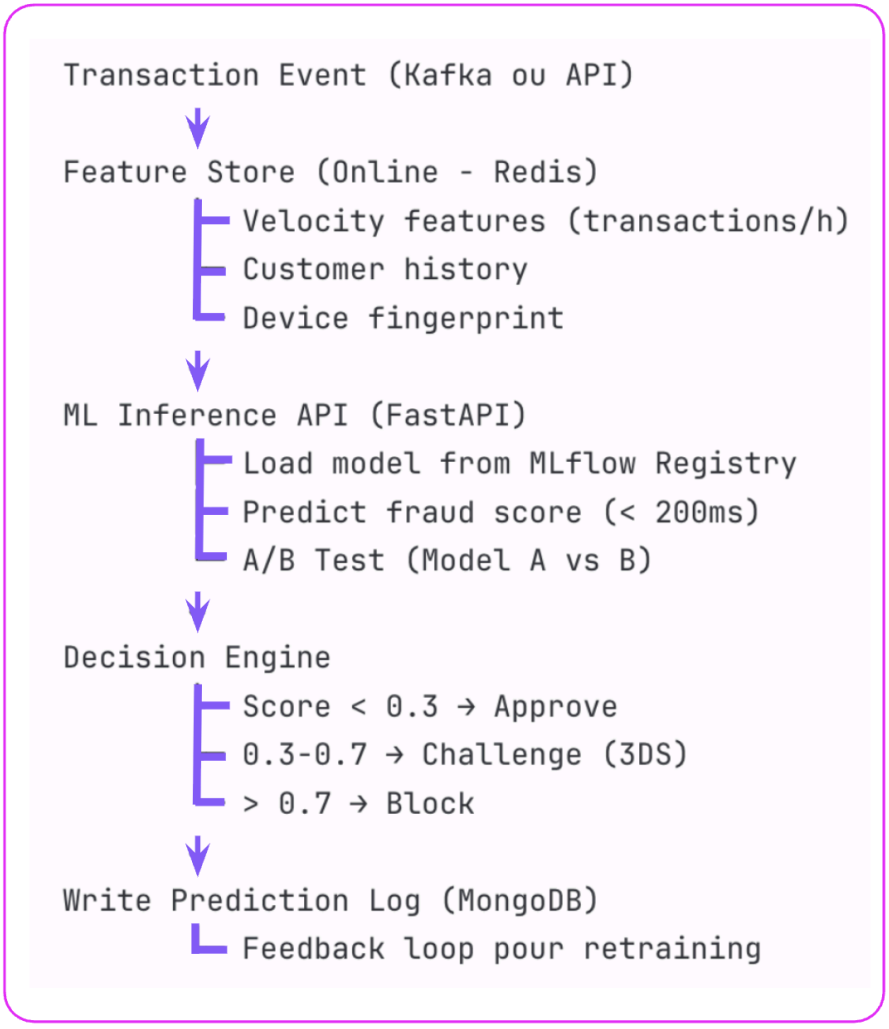

Feature Store (Feast)

1. Configuration Feast
2. Définition Features
3. Processus de Training
    DAG Airflow : ml_fraud_model_training_weekly
4. Fonction Training (pseudo-code)
5. Serving en Production
    API FastAPI
6. A/B Testing
    Routing Logic
    Analyse Résultats A/B

8. Stratégies de Synchronisation

Vue d'Ensemble

La synchronisation multi-systèmes nécessite des stratégies adaptées selon les besoins de cohérence.

Patterns de Cohérence

Système	Pattern	Latence	Garanties
OLTP (PostgreSQL)	**Cohérence forte (ACID)**	**Immédiate**	**Lecture après écriture**
OLTP → Kafka	**Eventually consistent**	**< 5s**	**At-least-once, idempotence**
Kafka → NoSQL	**Eventually consistent**	**< 10s**	**At-least-once**
OLTP → OLAP	**Eventually consistent**	**2-4h**	**Daily batch**
Feature Store	**Read-your-writes**	**< 1s online**	**Point-in-time correct**

Stratégie 1 : Exactly-Once Semantics (Kafka)

- Chaque message a ID unique
- Broker déduplique automatiquement
- Transactions distribuées Kafka
- Garantie : Message traité exactement une foi

Stratégie 2 : Idempotence (Écritures)

- Opérations répétables sans effet de bord
- Clé naturelle unique (transaction_id)
- Retry safe

Stratégie 3 : Conflict Resolution

Stratégie 4 : Change Data Capture (CDC)

Stratégie 5 : Two-Phase Commit (Évité)

⚠️ **Non recommandé pour systèmes distribués :**

- Latence élevée
- Point de défaillance unique (coordinateur)
- Bloque ressources

Alternative : Eventual consistency + compensation (sagas

9. Orchestration & Planification

Vue d'Ensemble Airflow

Environnement :

- **Scheduler** : Exécute DAGs selon schedule
- **Webserver** : Interface web pour monitoring
- **Executor** : CeleryExecutor (workers distribués)
- **Metadata DB** : PostgreSQL (état DAGs, runs, logs)
- **Message Broker** : Redis (queue tâches)

DAGs Principaux

DAG	Schedule	Durée	Priorité	Description
daily_oltp_to_dwh	2h00 UTC	2h	Haute	ETL quotidien vers Snowflake
hourly_feature_refresh	Toutes les heures	15min	Moyenne	Refresh Feature Store offline
weekly_ml_training	Dimanche 2h00	4h	Haute	Réentraînement modèles ML

daily_customer_360_build	6h00 UTC	1h	Moyenne	Agrégation profils clients
monthly_compliance_report	1er du mois 0h00	30min	Haute	Rapports GDPR/PCI-DSS

SLA & Monitoring

Métriques Airflow :

- DAG Success Rate : > 99%
- Task Duration : P95 < 2x median
- Scheduler Lag : < 30s
- Task Retry Rate : < 5%

10. Monitoring & Alerting

Architecture de Monitoring

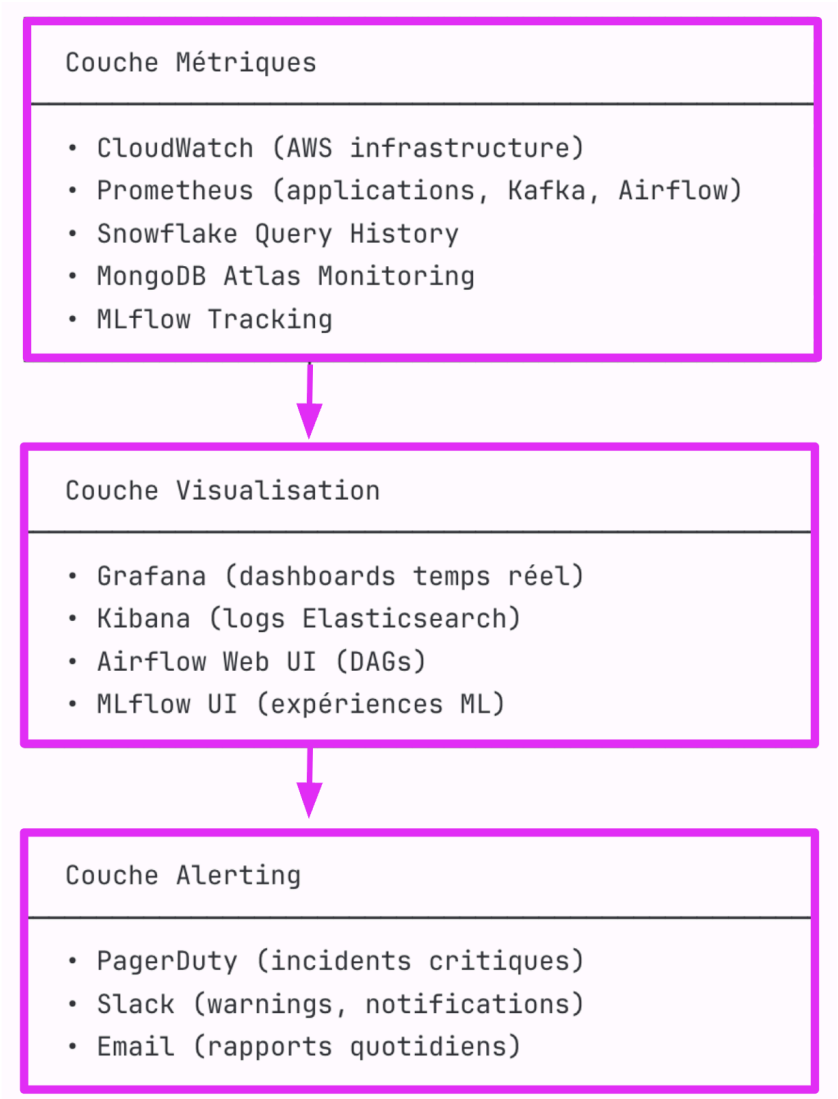

Métriques Clés par Système

OLTP (PostgreSQL) :

- Transactions/seconde
- Latence requêtes (P50, P95, P99)
- Taux erreurs connexions
- Taille base de données
- Replication lag (réplicas)

Kafka :

- Messages/seconde par topic
- Consumer lag par groupe
- Broker health

- Disk usage
- Under-replicated partitions

Snowflake :

- Credits consommés/heure
- Query duration (P95)
- Queue time
- Data scanned/query
- Failed queries

MongoDB :

- Operations/seconde (read/write)
- Connections actives
- Replication lag
- Index usage
- Document count/collection

Pipelines :

- DAG success rate
- Task duration vs baseline
- Data quality metrics
- Records processed/hour
- Pipeline end-to-end latency

Dashboards Grafana

Dashboard : Pipeline Health

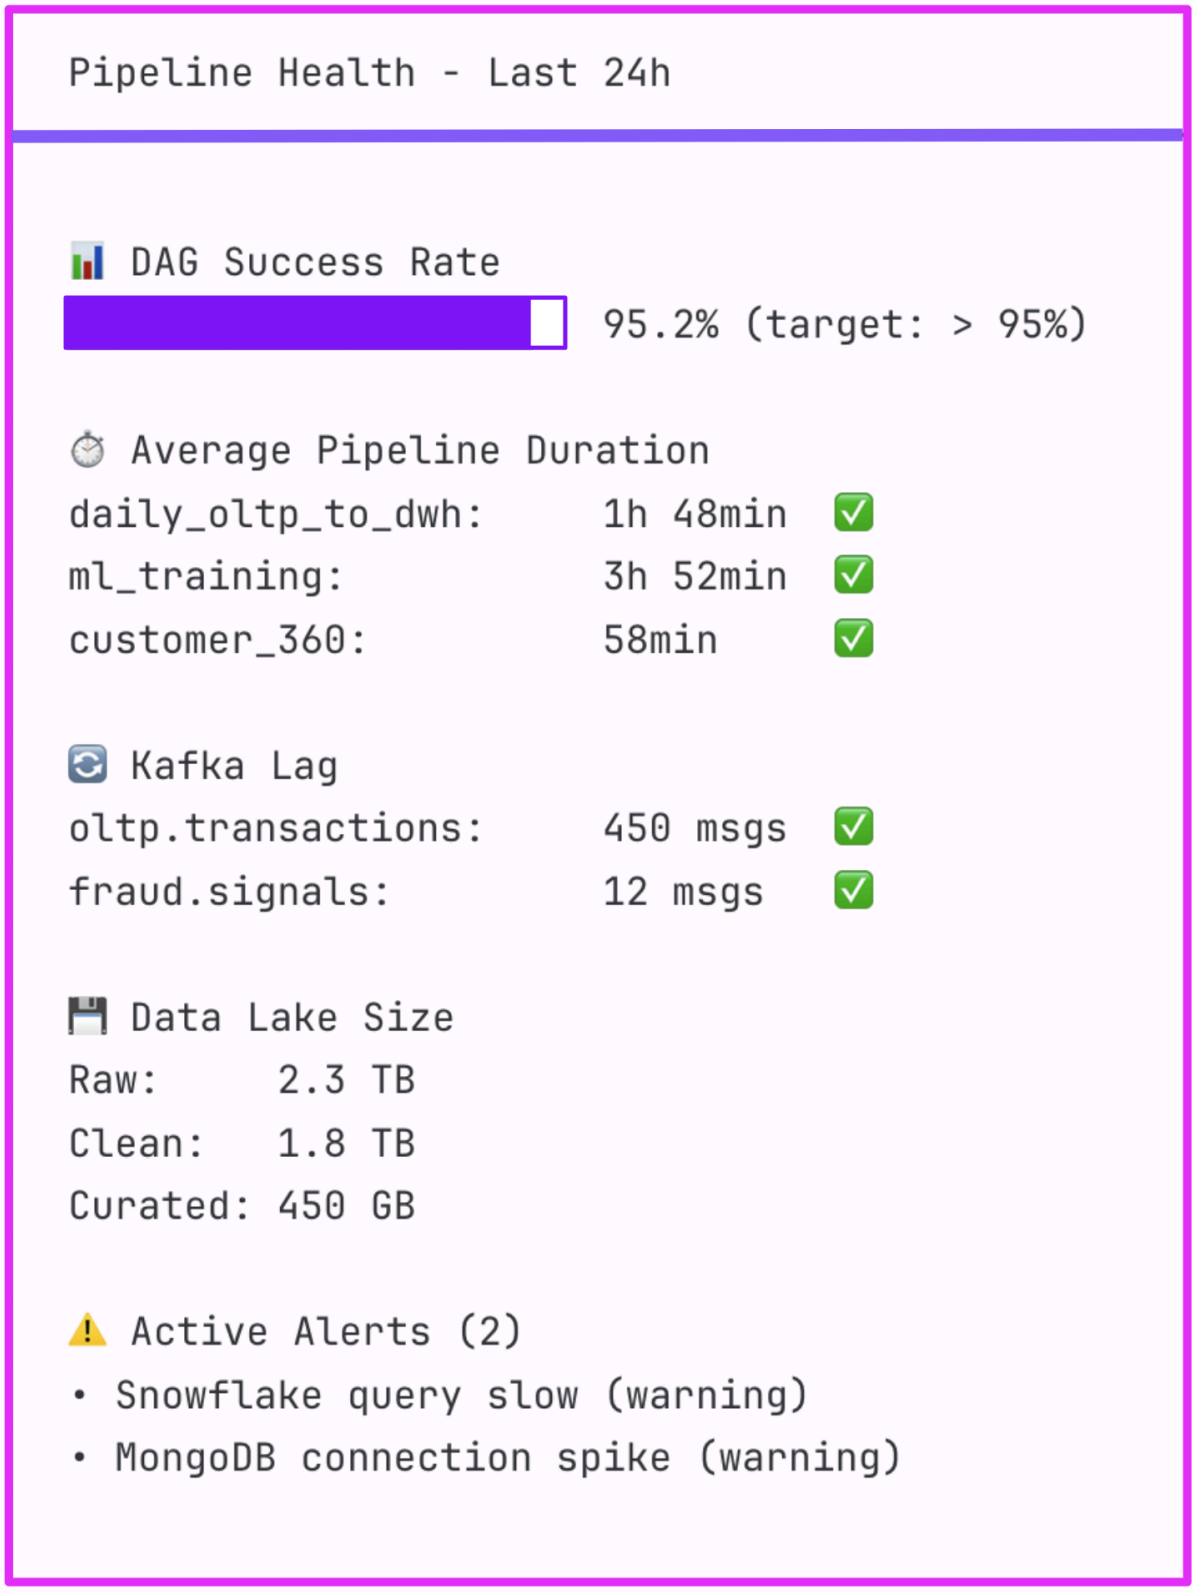

Règles d'Alerting

Critiques (PagerDuty)
Warnings (Slack) : notifications Slack

11. Gestion des Erreurs & Récupération

Stratégies par Type d'Erreur

Erreurs Transitoires (Retry)

Exemples :

- Timeouts réseau
- Broker Kafka temporairement indisponible
- Snowflake warehouse en cours de démarrage

Erreurs Permanentes (Fail Fast)

Exemples :

- Données corrompues
- Violation contrainte unicité
- Format données invalide

Erreurs Partielles (Continue avec Log)

Exemples :

- Quelques enregistrements invalides
- Enrichissement échoué pour subset

Plan de Disaster Recovery

Scénario 1 : Perte Base OLTP

RTO : 1 heure
RPO : 5 minutes

Procédure :

1. Basculer vers réplica read (promote vers primary)
2. Rediriger applications vers nouveau primary
3. Rétablir réplication depuis backup
4. Valider cohérence données

Scénario 2 : Corruption Data Lake

RTO : 4 heures
RPO : 24 heures (dernier backup)

Procédure :

1. Identifier zone corrompue (Raw/Clean/Curated)
2. Restaurer depuis backup S3 (versioning activé)
3. Re-exécuter pipelines depuis timestamp corruption
4. Valider qualité données restaurées

Scénario 3 : Indisponibilité Snowflake

RTO : 2 heures
RPO : 0 (données persistées S3)

Procédure :

1. Attendre rétablissement service (SLA Snowflake 99.9%)
2. Si prolongé : Activer cluster Snowflake région secondaire
3. Recharger depuis S3 Curated (idempotent)
4. Rediriger outils BI vers nouveau cluster

12. Performance & SLA

SLA Globaux

Métrique	Target	Mesure	Pénalité si Manqué
Disponibilité OLTP	**99.9%**	**Uptime mensuel**	**Crédit 10% facture**
Latence API Fraude	**< 200ms (P95)**	**Temps réponse**	**Escalation CTO**
Fraîcheur OLAP	**T+4h**	**Data available**	**Rapport incident**
Success Rate Pipelines	**> 95%**	**DAG runs**	**Investigation requise**

Perte Données	**0**	**Records in vs out**	**Incident majeur**

Optimisations Performance

OLTP (PostgreSQL)

Partitionnement :

Connection Pooling

Kafka

Producer Tuning

Consumer Tuning :

Snowflake

Clustering Keys :

Result Cache :

Materialized Views :

MongoDB

Indexes :

Sharding :

Benchmarks

Pipeline	Volume Données	Durée Actuelle	Objectif	Status
CDC Streaming	10M msgs/jour	3.2s latence	< 5s	✅

ETL Batch	10M transactions	1h 48min	< 2h	✅
ML Training	100M samples	3h 52min	< 4h	✅
Feature Refresh	5M features	12min	< 15min	✅
Customer 360	50M clients	58min	< 1h	✅

Conclusion

Cette architecture de pipelines de données offre :

✅ **Scalabilité** : Gère 50 000 TPS avec capacité croissance 10x
✅ **Fiabilité** : 99.9% uptime, récupération automatique
✅ **Performance** : Latence < 200ms fraude, fraîcheur données < 4h
✅ **Conformité** : GDPR/CCPA/PCI-DSS by design
✅ **Observabilité** : Monitoring complet, alerting proactif

Prochaines Étapes

1. **Phase 1 (Mois 1-2)** : Implémentation pipelines CDC et batch
2. **Phase 2 (Mois 3-4)** : Intégration NoSQL et Feature Store
3. **Phase 3 (Mois 5-6)** : Déploiement ML en production avec A/B testing
4. **Phase 4 (Mois 6+)** : Optimisation continue et scaling

Annexes

- **Annexe A** : Scripts d'installation et configuration
- **Annexe B** : Runbooks opérationnels
- **Annexe C** : Architecture Decision Records (ADR)
- **Annexe D** : Plan de formation équipe

Document Version : 1.0
Dernière Mise à Jour : Novembre 2025
Prochaine Revue : Trimestre Q1 2026