AIA Bloc_02 : stripe

Security & Governance

GDPR | CCPA | PCI-DSS
Recommandations Stratégiques

Vue d'Ensemble

Pour une plateforme de paiement internationale comme Stripe, la conformité réglementaire n'est **pas une option** mais un **impératif business**. Trois réglementations majeures structurent notre architecture de données :

Réglementation	Juridiction	Impact Prioritaire	Pénalités Maximales
GDPR	Union Européenne (27 pays)	Protection données personnelles	4% CA global ou €20M
CCPA	Californie (USA)	Transparence & opt-out	$7,500 par violation
PCI-DSS	Mondial (paiements carte)	Sécurité données bancaires	Retrait licence + amendes

Principe Directeur

> **"Privacy & Security by Design"** : La conformité doit être **intégrée dès la conception** de l'architecture, pas ajoutée après coup.

Comparatif GDPR vs CCPA : les différences

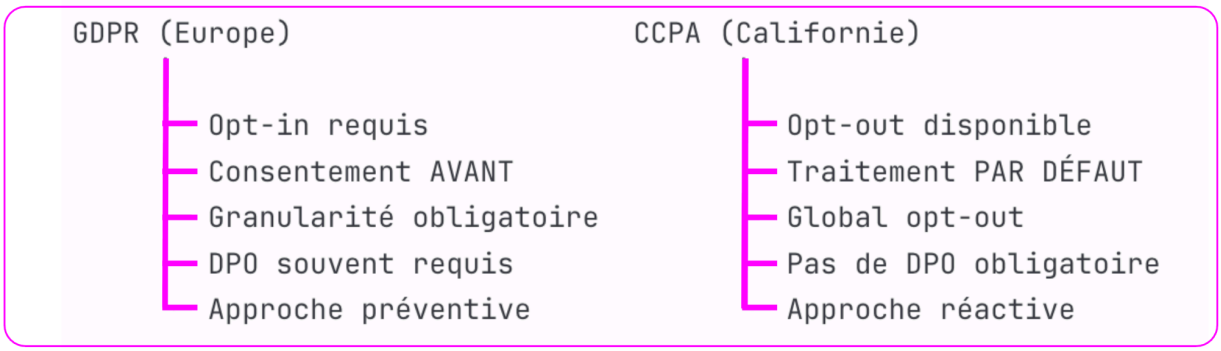

Tableau Synoptique des Exigences

Aspect	GDPR 🇪🇺	CCPA 🇺🇸	Recommandation Stripe
Consentement	Opt-in explicite	Opt-out sur demande	Implémenter les deux selon géolocalisation
Base légale	6 bases légales définies	Notification suffisante	Documenter base légale par traitement
Définition "vente"	Transfert contrôle données	Partage tiers (même gratuit)	Mapper tous les partages tiers
Droits individus	8 droits (accès, rectification, etc.)	5 droits principaux	Unifier dans portail self-service
Délai réponse	1 mois (extensible à 3)	45 jours (extensible à 90)	Target interne : 15 jours
Portée territoriale	Résidents UE partout	Résidents CA (même hors CA)	Détection géographique IP
UI obligatoire	Cookie banner (opt-in)	Lien "Do Not Sell" (opt-out)	Design adaptatif selon région
Amendes	Jusqu'à 4% CA global	$2,500-$7,500 par violation	GDPR = risque financier majeur

Recommandations par Composant d'Architecture

1. OLTP (PostgreSQL) - Source de Vérité

Objectif : Stocker PII de manière sécurisée avec capacité GDPR/CCPA

Recommandations Prioritaires

Données Sensibles

- Chiffrement at-rest : tablespaces PostgreSQL chiffrés (AES-256)
- Chiffrement colonnes : `pgcrypto` pour email, phone, adresse
- Tokenization : Cartes bancaires → tokens (jamais PAN complet)
- Row-Level Security : Isolation multi-tenant par merchant_id

Gestion Consentements

- Table dédiée `customer_consent` avec :
  - Détection juridiction automatique
  - Flags GDPR (opt-in granulaire par purpose)
  - Flags CCPA (opt-out global vente)
  - Versioning consentements (traçabilité)
  - Timestamps précis (audit)

Droits Individus

- **Procédures stockées pour :**
  - Export données (Right to Access)
  - Anonymisation (Right to Erasure - attention : pas suppression totale)
  - Rectification (Right to Rectification)
- **Logs de toutes les opérations GDPR/CCPA**

Architecture Données PCI-DSS

Jamais stocker :

- ❌ Numéro carte complet (PAN)
- ❌ CVV/CVV2/CVC2
- ❌ Données piste magnétique

Autorisé à stocker :

- ✅ Token (ex: `tok_visa_4242`)
- ✅ **4 derniers chiffres**
- ✅ **Date expiration**
- ✅ **Fingerprint (hash pour déduplication)**

---

2. Streaming Layer (Kafka) - Données en Transit

Objectif : Capturer événements en temps réel tout en protégeant PII

Recommandations Prioritaires

Pseudonymisation Avant Kafka

- **Hash emails** → `SHA256(email + salt + year)`
- Mask IP addresses → Conserver subnet uniquement (`185.123.0.0/16`)
- Truncate timestamps → Précision minute (pas milliseconde)
- Suppress device fingerprints → Remplacer par hash

Sécurité Kafka

- SSL/TLS pour tous les brokers
- SASL authentication (SCRAM-SHA-512)
- ACLs par topic (qui peut lire/écrire)
- Logs chiffrés sur disque

Topics de Consentement

- Topic dédié : `customer.consent.changed`
- Propagation temps réel des préférences GDPR/CCPA
- Consommation par tous les services downstream
- Retention : 90 jours (audit)

3. Data Lake (S3) - Stockage Intermédiaire

Objectif : Stocker données brutes/transformées avec zones sécurisées

Recommandations Prioritaires

Zone-Based Security Model

```
S3 Bucket: stripe-datalake
│
├─ /raw-zone/
│   ├─ Encryption: SSE-KMS (clés par région)
│   ├─ Access: Data Engineers uniquement (IAM strict)
│   ├─ Retention: 90 jours puis archivage Glacier
│   └─ Contient PII pseudonymisées
│
├─ /clean-zone/
│   ├─ Encryption: SSE-KMS
│   ├─ Access: Data Engineers + Data Scientists
```

```
│   ├─ Retention: 1 an
│   └─ PII hashées, validées
│
└─ /curated-zone/
    ├─ Encryption: SSE-S3 (suffisant car anonymisé)
    ├─ Access: Analytics Team + BI Tools
    ├─ Retention: 7 ans (compliance financière)
    └─ Données ANONYMISÉES (pas de PII identifiables)
```

✅ **Bucket Policies**

- Bloquer accès non-TLS (force HTTPS)
- IP whitelisting (VPN corporate uniquement)
- MFA delete (protection suppression accidentelle)
- Versioning activé (récupération en cas erreur)

✅ **Anonymisation au Pipeline ETL**

- **AVANT écriture dans curated-zone :**
  - Généralisation (âge → tranche d'âge)
  - Agrégation (K-anonymity, k ≥ 5)
  - Suppression PII directes (email, phone, adresse)
  - Hash irréversible des identifiants

4. OLAP (Snowflake) - Analytics & Reporting

Objectif : Zéro PII identifiables, données 100% anonymisées

Recommandations Prioritaires

Principe Fondamental

> ⚠️ OLAP ne doit JAMAIS contenir de PII réversibles
>
> Contrairement à OLTP qui peut chiffrer, OLAP doit anonymiser irréversiblement.

Tables Dimensions - Données Anonymisées

❌ **NE JAMAIS stocker dans OLAP :**

- Email complets
- Noms/Prénoms
- Adresses complètes
- IP addresses complètes

- Numéros de téléphone
- Dates de naissance exactes

STOCKER dans OLAP :

- Domaines email (ex: `@gmail.com`)
- Tranches d'âge (ex: `25-34`)
- Régions (ex: `Ile-de-France`)
- Préfixes codes postaux (ex: `750`)
- Hash clients (`SHA256(customer_id)`)
- Années (pas dates complètes)

Contrôles d'Accès Snowflake

- Network policies (VPN uniquement)
- MFA obligatoire (tous les utilisateurs)
- SSO via SAML (Okta/Azure AD)
- Row Access Policies (isolation merchant)
- Audit logs (365 jours minimum)

Pas de Dynamic Masking pour GDPR

- ❌ Le masking dynamique est insuffisant (données en clair en base)
- Anonymisation irréversible au pipeline ETL
- Approche conforme : Data minimization dès la conception

---

5. NoSQL (MongoDB) - Flexibilité & Logs

Objectif : Stocker données semi-structurées avec conformité

Recommandations Prioritaires

Field-Level Encryption

- Client-Side Field Level Encryption (CSFLE)
- PII chiffrées : email, phone dans `customer_360`
- Clés gérées via KMS (AWS KMS / Azure Key Vault)
- Rotation clés automatique (90 jours)

Collections Spécialisées

Logs (Time-Series) :

- TTL automatique (30-90 jours)

- IP addresses masquées
- Pas de PII en clair

Fraud Signals :

- Features anonymisées pour ML
- Customer hash (pas ID direct)
- Scores et décisions seulement

Customer 360 :

- Vue agrégée (pas données brutes)
- Chiffrement colonnes sensibles
- Suppression automatique si GDPR deletion

Sharding & Access Control

- Sharding par customer_hash (distribution)
- RBAC MongoDB (rôles par use case)
- Audit logs activés (tous les accès)
- Connection chiffrée (TLS 1.3)

Consent Management Platform (CMP) - Cœur de la Conformité

Architecture Recommandée

Consent Management Platform (CMP)

1. DÉTECTION JURIDICTION
   - Géolocalisation IP (GeoIP2)
   - Détermination automatique : EU / CA / UK / Other
   - Fallback : Applique règle la plus stricte (EU)

2. INTERFACE ADAPTATIVE
   - EU → Cookie banner (opt-in obligatoire)
   - CA → Lien "Do Not Sell" (opt-out disponible)
   - Multilangue (détection locale)
   - Mobile-responsive

3. STOCKAGE CONSENTEMENTS
   - Base OLTP (table customer_consent)
   - Versioning (historique complet)
   - Granularité par purpose (GDPR)
   - Global opt-out sale (CCPA)

4. PROPAGATION TEMPS RÉEL
   - Event Kafka → Tous les services
   - Cache Redis (low-latency checks)
   - Notification partenaires externes si opt-out

5. APIS SELF-SERVICE
   - GET /privacy/my-data (Right to Access)
   - POST /privacy/update-consent (Modification)
   - DELETE /privacy/delete-me (Right to Erasure)
   - POST /privacy/ccpa/opt-out (CCPA specific)

Solutions CMP Recommandées

Solution	Avantages	Inconvénients	Recommandation
OneTrust	Leader marché, GDPR+CCPA+50+ lois	Coûteux ($50k+/an)	✅ Entreprise >500M$ CA
Cookiebot	Simple, bon rapport qualité/prix	Moins de features avancées	✅ PME/Startup
TrustArc	Complet, bon support	Interface complexe	⚠️ Si besoin global compliance
Custom (maison)	Contrôle total, pas de coût licence	Dev/maintenance important	⚠️ Si ressources tech suffisantes

Recommandation Stripe : OneTrust (justifié par volume et criticité)

Droits des Individus - Implémentation Recommandée

Matrice des Droits GDPR + CCPA

Droit	GDPR	CCPA	Délai	Complexité	Priorité
Accès	✅	✅	30j/45j	Moyenne	🔴 Élevée
Rectification	✅	✅ (2023+)	30j	Faible	🟡 Moyenne
Suppression	✅	✅	30j/45j	Élevée	🔴 Élevée
Portabilité	✅	❌	30j	Moyenne	🟡 Moyenne
Opposition	✅	❌	Immédiat	Faible	🟡 Moyenne
Opt-out sale	N/A	✅	Immédiat	Moyenne	🔴 Élevée (CA)
Limitation	✅	❌	30j	Moyenne	🟢 Faible
Décision auto	✅	❌	30j	Faible	🟢 Faible

Workflow Recommandé : Right to Erasure (Exemple)

Processus de Suppression (Right to Erasure / Delete)

1. Requête Client
   - Via portail self-service ou email DPO
   - Vérification identité (2FA / email confirmation)
   - Justification optionnelle

2. Évaluation Exceptions (< 48h)
   - Obligations légales ? (ex: 7 ans transactions)
   - Litiges en cours ?
   - Intérêts légitimes impérieux ?
   - Décision : Suppression totale / partielle / refus

3. Planification (si approuvé)
   - Job asynchrone (Airflow DAG)
   - Ordre : OLAP → NoSQL → Datalake → OLTP (inverse)
   - Backups séparés (conformité légale 7 ans)

4. Exécution Multi-Systèmes
   - Snowflake : DELETE customer records
   - MongoDB : db.customer_360.deleteOne()
   - S3 : Suppression fichiers (si identifiables)
   - PostgreSQL : Anonymisation (pas suppression)
     → email = 'deleted_{id}@anonymized.local'

5. Confirmation & Audit
   - Email confirmation client (< 30 jours)
   - Log exhaustif (qui, quand, quoi, pourquoi)
   - Notification DPO
   - Preuve de conformité archivée

⚠️ **ATTENTION : Suppression ≠ Deletion complète**

- Données transactionnelles : Anonymisation (pas suppression)
- Obligations légales : Conservation 7 ans (finance)
- Approche : PII supprimées, transactions anonymisées conservées

PCI-DSS - Sécurité Données Bancaires

Les 12 Exigences PCI-DSS (Synthèse)

	Exigence	Impact Architecture Stripe	Priorité
1	Pare-feu et segmentation réseau	VPC privés, pas d'accès Internet direct	🔴
2	Pas de mots de passe par défaut	Rotation secrets automatique	🟡
3	Protéger données cartes stockées	Tokenization (pas de PAN)	🔴
4	Chiffrer transmissions réseaux publics	TLS 1.3 obligatoire	🔴
5	Antivirus/Malware	Solutions endpoint protection	🟡
6	Systèmes et apps sécurisés	Scans vulnérabilités réguliers	🟡
7	Accès données sur besoin métier	RBAC strict, principe moindre privilège	🔴
8	Authentification forte	MFA obligatoire, SSO	🔴
9	Accès physique restreint	Datacenters Tier IV certifiés	🟢
10	Tracer accès ressources réseau	Audit logs 365 jours minimum	🔴
11	Tests sécurité réguliers	Pentests annuels + bug bounty	🟡
12	Politique sécurité info	Documentation + formation équipe	🟡

Architecture PCI-DSS : Network Segmentation

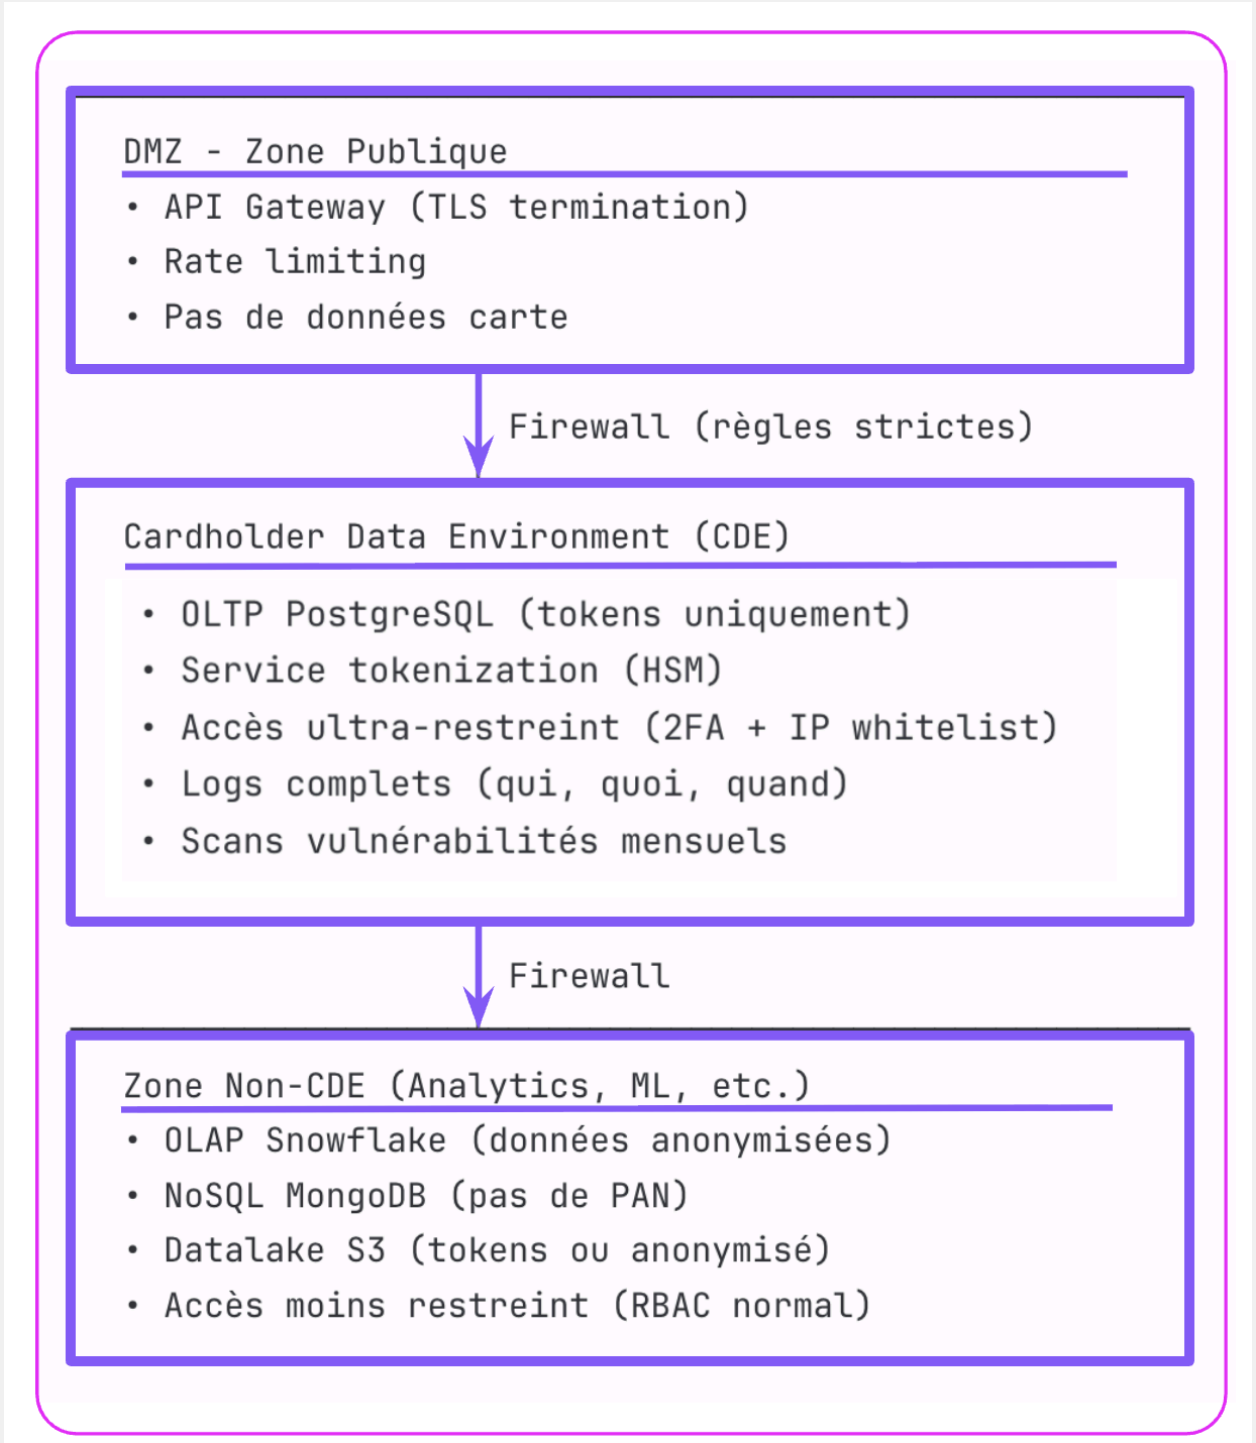

Exemple de Table pour gérer les consentements GDPR + CCPA

```
CREATE TABLE customer_consent (
    consent_id UUID PRIMARY KEY DEFAULT uuid_generate_v4(),
    customer_id UUID NOT NULL REFERENCES
customer(customer_id),

    -- Détection juridiction
    jurisdiction VARCHAR(10) NOT NULL, -- 'EU', 'CA',
'US-OTHER', etc.
    ip_address INET,
    detected_at TIMESTAMP NOT NULL DEFAULT
CURRENT_TIMESTAMP,

    -- GDPR (EU) - Opt-in
    gdpr_consent_given BOOLEAN DEFAULT FALSE,
    gdpr_consent_timestamp TIMESTAMP,
    gdpr_purposes JSONB DEFAULT '{}', -- {"marketing":
true, "analytics": false}

    -- CCPA (California) - Opt-out
    ccpa_opt_out_sale BOOLEAN DEFAULT FALSE,
ccpa_opt_out_timestamp TIMESTAMP,
    ccpa_do_not_sell_requested BOOLEAN DEFAULT FALSE,

    -- Historique et audit
    consent_version VARCHAR(10), -- "v2.1" (version des
CGU)
    consent_method VARCHAR(50), -- "web_banner",
"api_call", "email"
    consent_text TEXT, -- Texte exact présenté

    -- Métadonnées
    created_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
    updated_at TIMESTAMP DEFAULT CURRENT_TIMESTAMP,
```

```
    is_active BOOLEAN DEFAULT TRUE,

    -- Constraints
    CONSTRAINT chk_jurisdiction CHECK (jurisdiction IN
('EU', 'CA', 'US-OTHER', 'UK', 'OTHER')),
    CONSTRAINT chk_gdpr_eu_only CHECK (
        (jurisdiction = 'EU' AND gdpr_consent_given IS NOT
NULL) OR
        (jurisdiction != 'EU')
    ),
    CONSTRAINT chk_ccpa_ca_only CHECK (
        (jurisdiction = 'CA' AND ccpa_opt_out_sale IS NOT
NULL) OR
        (jurisdiction != 'CA')
    )
);

-- Index
CREATE INDEX idx_consent_customer ON
customer_consent(customer_id, is_active);
CREATE INDEX idx_consent_jurisdiction ON
customer_consent(jurisdiction);
CREATE INDEX idx_consent_ccpa_optout ON
customer_consent(ccpa_opt_out_sale)
    WHERE jurisdiction = 'CA';

-- Audit trigger
CREATE TRIGGER consent_audit AFTER UPDATE ON
customer_consent
    FOR EACH ROW EXECUTE FUNCTION log_consent_change();
```

Techniques d'Anonymisation Conformes

1. Hashing Irréversible (pour Comptage)

```
-- ❌ Dans OLAP : NE PAS stocker
email: "jean.dupont@example.com"

-- ✅ Dans OLAP : Stocker hash
customer_hash: SHA256("jean.dupont@example.com" + salt)
→ "8f7a3b2c1d9e5f4a3b2c1d9e5f4a3b2c"

-- Usage analytique possible :
SELECT customer_hash, COUNT(*) as transaction_count
FROM fact_transaction
GROUP BY customer_hash;  -- Comptage unique OK

-- Objectif : ne pas pouvoir retrouver l'email original !
```

Implementation dbt :

```
-- models/staging/stg_customers.sql
SELECT
    -- ❌ PAS d'email brut
    -- email,

    -- ✅ Hash irréversible
    {{ hash_pii('email') }} as customer_hash,

    -- ✅ Extraction domaine seulement (analytics)
    SPLIT_PART(email, '@', 2) as email_domain,

    -- ✅ Agrégation géographique
    country_code,

    -- ✅ Généralisation âge
    CASE
        WHEN age BETWEEN 18 AND 24 THEN '18-24'
```

```
        WHEN age BETWEEN 25 AND 34 THEN '25-34'
        WHEN age BETWEEN 35 AND 44 THEN '35-44'
        ELSE '45+'
    END as age_group

FROM {{ source('oltp', 'customer') }}
```

2. Agrégation (K-Anonymity)

```
-- ❌ Données individuelles (identifiables)
customer_id | age | city      | salary
------------|-----|-----------|--------
uuid_123    | 32  | Paris     | 45000
uuid_456    | 28  | Lyon      | 42000

-- ✅ Données agrégées (anonymes si k ≥ 3-5)
age_group | city_region | avg_salary | customer_count
----------|-------------|------------|---------------
25-34     | Ile-de-France| 43500    | 127
```

Règle K-Anonymity :

- Chaque combinaison doit contenir au minimum **k individus** (généralement k=5)
- Si moins de k : **supprimer ou regrouper** davantage

```
-- dbt macro pour k-anonymity
{% macro ensure_k_anonymity(group_by_cols, k=5) %}
HAVING COUNT(*) >= {{ k }}
{% endmacro %}

-- Utilisation
```

```
SELECT
    age_group,
    country,
    COUNT(*) as customer_count,
    AVG(lifetime_value) as avg_ltv
FROM dim_customer
GROUP BY age_group, country
{{ ensure_k_anonymity(['age_group', 'country'], 5) }}
```

```
-- ❌ Trop précis (identifiable)
address: "123 Rue de Rivoli, 75001 Paris"
birth_date: "1990-03-15"
ip_address: "185.123.45.67"

-- ✅ Généralisé (anonyme)
postal_code_prefix: "750"  -- Seulement 3 premiers chiffres
birth_year: 1990           -- Seulement l'année
ip_range: "185.123.0.0/16" -- Subnet seulement
```

```
-- Service séparé (Token Vault) - accès ultra-restreint
CREATE TABLE token_mapping (
    customer_token UUID PRIMARY KEY,
    customer_id_oltp UUID,  -- Chiffré at rest
    created_at TIMESTAMP,
    accessed_count INTEGER
);

-- OLAP contient SEULEMENT le token
CREATE TABLE dim_customer (
    customer_key INTEGER PRIMARY KEY,
    customer_token UUID,  -- ✅ Pas de PII
    age_group VARCHAR(10),
```

```
    country_code VARCHAR(3),
    segment VARCHAR(50)
    -- ❌ PAS d'email, nom, adresse, etc.
);
```

Règles strictes :

- Token Vault = base séparée, accès DPO uniquement
- Logs exhaustifs de chaque accès
- Justification obligatoire (ticket GDPR)
- Retention: suppression token après X mois

Correction de OLAP

```
CREATE TABLE dim_customer (
    customer_key INTEGER PRIMARY KEY,

    --  Identifiant pseudonymisé (hash one-way)
    customer_hash VARCHAR(64) NOT NULL,

    --  Données agrégées/généralisées
    age_group VARCHAR(10),          -- "25-34" au lieu de
32
    country_code VARCHAR(3),        -- "FR" (OK, pas PII
seul)
    region VARCHAR(50),             -- "Ile-de-France"
    postal_code_prefix VARCHAR(3),  -- "750" au lieu de
"75001"

    --  Comportement (anonyme)
    customer_segment VARCHAR(50),   -- "High_Value",
"Regular"
    lifetime_transactions INTEGER,
```

```
    lifetime_value DECIMAL(18,2),
    first_transaction_year INTEGER, -- 2023 (pas date
complète)

    --  Métadonnées non-identifiantes
    preferred_language VARCHAR(10),
    currency VARCHAR(3),

    -- ❌ SUPPRIMÉ (PII)
    -- email VARCHAR(255),           ← INTERDIT
    -- phone_number VARCHAR(20),     ← INTERDIT
    -- full_name VARCHAR(255),       ← INTERDIT
    -- birth_date DATE,              ← INTERDIT
    -- ip_address INET,              ← INTERDIT

    -- SCD Type 2
    effective_from TIMESTAMP,
    effective_to TIMESTAMP,
    is_current BOOLEAN
);
```

Table FACT_TRANSACTION

```
CREATE TABLE fact_transaction (
    transaction_key BIGINT PRIMARY KEY,

    -- FKs vers dimensions anonymisées
    date_key INTEGER,
    customer_key INTEGER,  -- → dim_customer (anonymisé)
    merchant_key INTEGER,

    -- ✅ Données transactionnelles (OK)
    amount DECIMAL(18,2),
```

```
    currency_code VARCHAR(3),
    status VARCHAR(20),

    -- ✅ Géographie agrégée
    country_code VARCHAR(3),
    region VARCHAR(50),

    -- ❌ SUPPRIMÉ (PII ou identifiable)
    -- ip_address INET,              ← INTERDIT
    -- device_fingerprint VARCHAR,   ← INTERDIT (unique
identifier)
    -- email VARCHAR,                ← INTERDIT

    -- ✅ Métriques agrégées OK
    fraud_score DECIMAL(5,4),
    processing_time_ms INTEGER
);
```

Airflow DAG avec Anonymisation

```
# tasks/anonymize_customer_data.py

def anonymize_pii(data):
    """Anonymisation irréversible avant chargement OLAP"""

    return {
        # Hash one-way (avec salt rotatif)
        'customer_hash': hashlib.sha256(
            (data['email'] + SALT +
str(data['created_at'].year)).encode()
        ).hexdigest(),
```

```
        #  Extraction domaine seulement
        'email_domain': data['email'].split('@')[1] if
data['email'] else None,

        #  Généralisation âge
        'age_group': get_age_group(data['age']),

        #  Géolocalisation agrégée
        'country_code': data['country'],
        'postal_code_prefix': data['postal_code'][:3] if
data['postal_code'] else None,

        #  Temporalité agrégée
        'first_transaction_year':
data['first_transaction_date'].year,

        # ❌ PII SUPPRIMÉES (pas chargées dans OLAP)
        # 'email': SUPPRIMÉ
        # 'phone': SUPPRIMÉ
        # 'full_address': SUPPRIMÉ
    }

# DAG Airflow
with DAG('daily_olap_load_gdpr_compliant') as dag:

    extract = PostgresOperator(
        task_id='extract_oltp',
        sql='SELECT * FROM customer WHERE updated_at >= {{
ds }}'
    )

    anonymize = PythonOperator(
        task_id='anonymize_pii',
```

```
        python_callable=anonymize_pii
    )

    load_snowflake = SnowflakeOperator(
        task_id='load_anonymized_to_olap',
        sql='COPY INTO dim_customer_staging FROM
@s3_anonymized_stage'
    )

    extract >> anonymize >> load_snowflake
```

Architecture Technique et Sécurité – Compléments Opérationnels

Ce document technique complète le cadre réglementaire défini ci-dessus en précisant les **implémentations concrètes validées pour chaque couche du système data, en alignement strict avec les principes de Privacy & Security by Design.**

1. Couche OLTP (PostgreSQL)

- Chiffrement : AES-256 au repos (tablespaces) + `pg_crypto` pour colonnes sensibles (email, téléphone).
- Tokenisation PCI-DSS : Aucun PAN complet stocké ; uniquement des tokens (`tok_visa_4242`) et les 4 derniers chiffres.
- Isolation marchands : `Row-Level Security` basée sur `merchant_id`.
- Gestion RGPD/CCPA : Table `customer_consent` avec détection juridictionnelle (IP), versioning et logs auditables.

2. Couche Streaming (Kafka)

- Pseudonymisation en amont :
    - Email → `SHA256(email + salt + année)`

    - IP → troncature en `/16` (`185.123.0.0`)
    - Suppression des empreintes de device
- Sécurité : TLS 1.3, SASL/SCRAM, ACLs par topic, logs chiffrés.
- Topic dédié : `customer.consent.changed` pour propagation temps réel des préférences.

3. Data Lake (S3) – Modèle par zones

- Raw Zone : Accès ingénieurs uniquement, chiffrement KMS, PII pseudonymisées, rétention 90j.
- Clean Zone : PII hashées, accès ingénieurs + data scientists, rétention 1 an.
- Curated Zone : Données anonymisées irréversiblement, agrégées (K-anonymity ≥ 5), rétention 7 ans.

4. Couche OLAP (Snowflake) – Zéro PII

- **Données conformes :**
    - `customer_hash` (SHA256), pas d'email
    - Tranches d'âge (ex: `25-34`), pas de date de naissance
    - Préfixe CP (`750`), pas d'adresse complète
    - Domaine email (`@gmail.com`), pas l'adresse
- Contrôles d'accès : VPC privé, MFA obligatoire, SSO, `Row Access Policies` par région (EU/US), audit logs 365j.
- ⚠ Pas de dynamic masking : l'anonymisation est irréversible au pipeline ETL, conformément au RGPD.

5. NoSQL (MongoDB)

- Chiffrement côté client (CSFLE) pour les PII via AWS KMS.
- Collections sécurisées :
    - `fraud_signals` : features anonymisées, hash client
    - `customer_360` : vue agrégée, suppression automatique en cas de demande RGPD
    - Logs : TTL (30–90j), IP masquées
- Sharding par `customer_hash`, RBAC strict, TLS 1.3.

6. Automatisation et Conformité Continue

- DAG Airflow dédié : exécute l’anonymisation (hashing, agrégation, suppression PII) avant chargement OLAP.
- Validation K-anonymity : macro dbt pour garantir k ≥ 5 dans les agrégats.
- Monitoring de conformité : alertes sur accès PII non autorisés, export massif, détection de données brutes en OLAP.